Sprawozdanie z projektu: Analiza częstotliwościowa

Wiktor Murawski

28 kwietnia 2026

1 Wstęp i opis aplikacji

Celem projektu było stworzenie aplikacji okienkowej umożliwiającej wczytanie pliku dźwiękowego w formacie `.wav`, wizualizację przebiegu czasowego oraz obliczenie i prezentację wybranych parametrów sygnału (m.in. głośności, energii krótkoczasowej, współczynnika przejść przez zero oraz wskaźnika ciszy).

Aplikacja została zrealizowana w języku `C#` (`.NET 8`) z wykorzystaniem frameworku `Windows Forms`. Do wizualizacji sygnałów wykorzystano bibliotekę `ScottPlot 5`, do wczytywania plików audio wykorzystano bibliotekę `NAudio`. Do FFT użyto biblioteki `FftSharp`.

Główne cechy aplikacji:

- Wczytywanie plików `.wav` (mono lub stereo o dowolnej częstotliwości próbkowania)
- Wyświetlanie przebiegu fali dźwiękowej
- Rysowanie wykresu widma częstotliwościowego poprzez zastosowanie FFT
- Wyznaczenie i rysowanie wykresów parametrów w dziedzinie częstotliwości na poziomie ramki
- Możliwość zmiany rozmiaru ramki oraz rozmiaru skoku
- Wybór stosowanej funkcji okienkowej
- Rysowanie spektrogramu
- Rysowanie wykresu częstotliwości krtaniowej obliczanej za pomocą cepstrum

Intefejs użytkownika

Interfejs aplikacji (przedstawiony na Rysunku 1):

- Pozwala użytkownikowi wczytać plik `.wav` (`Plik > Wczytaj plik audio`)
- Wyświetla wykres oryginalnego sygnału oraz wykresy parametrów wyznaczonych na poziomie ramek z lewej strony okna
- Umożliwia ustawienie rozmiaru ramki, rozmiaru skoku, typu funkcji okienkowej i innych opcji z prawej strony okna

- Prezentuje wyznaczone parametry na poziomie klipu w prawym dolnym rogu okna

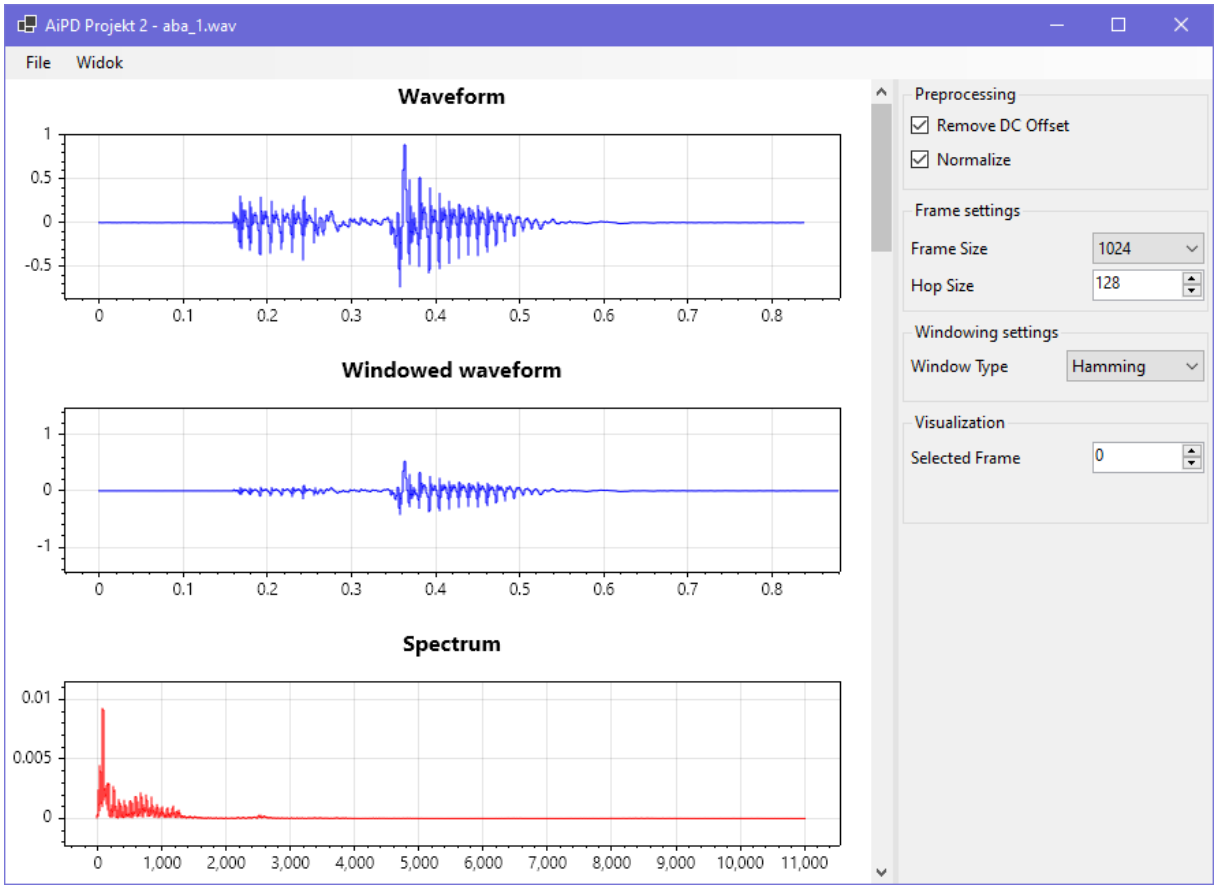

Rysunek 1: Przykładowy wygląd interfejsu aplikacji po wczytaniu krótkiego sygnału mowy (słowo "aba")

2 Opis zastosowanych metod

Wczytywanie sygnału

Plik audio jest wczytywany za pomocą `AudioFileReader` z biblioteki `NAudio`. W przypadku pliku mono próbki wczytywane są od razu, w przypadku pliku stereo jest on konwertowany do sygnału mono poprzez wzięcie średniej z obu kanałów. Dla większej liczby kanałów wyświetlany jest błąd o nieobsługiwanej liczbie kanałów.

2.1 Wstępne przetwarzanie sygnału

Przed właściwym przetwarzaniem wczytanego sygnału następuje preprocessing. Zgodnie z ustawieniami wybranymi przez użytkownika, sygnał może zostać poddany usunięciu przesunięcia składowej stałej (DC offset) i/lub normalizacji.

2.2 Podział sygnału na ramki

Przy przetwarzaniu sygnału, sygnał jest dzielony na ramki o długości ustalonej przez użytkownika (do wyboru ramki długości 128, 256, 512, 1024, 2048 lub 4096 próbek). Ramki mogą na siebie nachodzić, zgodnie z wybranym przez użytkownika rozmiarem skoku. Gdy rozmiar skoku równy jest rozmiarowi ramki, overlapping ramek nie zachodzi. W przypadku gdy ilość wczytanych próbek nie jest podzielna przez rozmiar ramki, ostatnie ramka dopełniana jest zerami.

2.3 Wyznaczanie widma częstotliwościowego

Widmo częstotliwościowe wyznaczane jest zarówno dla każdej ramki jak i dla całego sygnału za pomocą FFT. Na całym sygnale i na każdej ramce stosowana jest funkcja okienkowej wybrana przez użytkownika (do wyboru okno prostokątne, trójkątne, Hamminga, Hanninga (van Hanna), Blackmana). Cały sygnał jest dopełniany zerami do najbliższej potęgi dwójki.

2.4 Cechy sygnału audio w dziedzinie częstotliwości na poziomie ramki

Poniższe cechy są obliczane dla każdej ramki sygnału osobno, gdzie $S_n(k)$ oznacza dyskretne widmo amplitudowe n-tej ramki uzyskane w wyniku transformacji Fouriera, N oznacza rozmiar ramki, a ω reprezentuje częstotliwość kątową.

2.4.1 Głośność (Volume)

$$Vol(n) = \frac{1}{N} \sum_{k=0}^{N-1} S_n^2(k)$$

Głośność jest miarą energii sygnału w dziedzinie częstotliwości. Obliczana jest jako średnia wartość kwadratów współczynników widma mocy dla danej ramki. Wysoka wartość tej cechy odpowiada fragmentom sygnału o dużej energii, natomiast wartości bliskie zeru odpowiadają fragmentom o bardzo małej amplitudzie lub ciszy.

2.4.2 Centroid częstotliwości (Frequency Centroid)

$$FC(n) = \frac{\int_0^\infty \omega S_n(\omega) d\omega}{\int_0^\infty S_n(\omega) d\omega}$$

Centroid częstotliwości reprezentuje „środek ciężkości"rozkładu energii widmowej – częstotliwość, względem której energia widma jest równomiernie rozłożona. Cecha ta jest silnie skorelowana z subiektywnym odczuciem jasności dźwięku przez człowieka: dźwięki jasne, bogate w wysokie częstotliwości (np. talerze perkusyjne) cechują się wysoką wartością FC, natomiast dźwięki niskie (np. bas) – niską. W praktyce aplikacja liczy to dyskretnie – całki zastępuje się sumami, a częstotliwość k-tego prążka wynosi $f_k = k \cdot f_s/N$, gdzie f_s to częstotliwość próbkowania.

2.4.3 Efektywna przepustowość (Effective Bandwidth)

$$BW^2(n) = \frac{\int\limits_0^\infty (\omega - FC(n))^2 S_n^2(\omega) d\omega}{\int\limits_0^\infty S_n^2(\omega) d\omega}$$

Efektywna przepustowość jest odchyleniem standardowym rozkładu energii widmowej względem centroidu częstotliwości. Opisuje, jak szeroko energia sygnału jest rozłożona wokół FC – wąskie pasmo oznacza sygnał o dobrze określonej częstotliwości dominującej (np. czysty ton), natomiast szerokie pasmo wskazuje na sygnał o energii rozproszonej po całym spektrum (np. szum). Wynik wyrażony jest w hercach.

2.4.4 Energie pasm (Band Energy)

$$BE_{[f_0,f_1]}(t) = \frac{\int\limits_{f_0}^{f_1} S_t^2(f) df}{\int w(\tau) d\tau}$$

Energia pasma określa zawartość energetyczną sygnału w wybranym przedziale częstotliwości $[f_0, f_1]$, znormalizowaną przez sumę współczynników okna analitycznego $w(\tau)$. Obliczenia wykonywane są dla czterech pasm częstotliwości odpowiadających pasmom krytycznym ludzkiego układu słuchowego: 0–630 Hz, 630–1720 Hz, 1720–4400 Hz oraz 4400–11025 Hz. Podział ten wywodzi się z modelu ślimaka ucha i odzwierciedla nieliniową charakterystykę percepcji częstotliwości przez człowieka.

2.4.5 Stosunek energii pasm (Band Energy Ratio)

$$ERSB_{[f_0,f_1]}(t) = BER_{[f_0,f_1]}(t) = \frac{BE_{[f_0,f_1]}(t)}{\left(\frac{\int S_t^2(f) df}{\int w(\tau) d\tau}\right)}$$

Stosunek energii pasma (ERSB, ang. *Energy Ratio Sub-Band*) określa udział energii danego pasma częstotliwości w całkowitej energii sygnału. Po rozwinięciu wzoru człon $\int w(\tau) d\tau$ skraca się zarówno w liczniku jak i mianowniku, przez co ERSB sprowadza się do stosunku energii pasma do całkowitej energii widma. Suma wszystkich czterech wartości ERSB wynosi zawsze jeden.

2.4.6 Płaskość widmowa (Spectral Flatness Measure)

$$SFM(b,n) = \frac{\sqrt[ih(b)-il(b)+1]{\prod\limits_{i=il(b)}^{ih(b)} S_n^2(i)}}{\frac{1}{ih(b)-il(b)+1} \sum\limits_{i=il(b)}^{ih(b)} S_n^2(i)}$$

Płaskość widmowa jest stosunkiem średniej geometrycznej do średniej arytmetycznej gęstości widmowej mocy w paśmie b, gdzie $il(b)$ i $ih(b)$ oznaczają odpowiednio dolny i górny indeks prążka dla tego pasma. Wartość bliska jedności wskazuje na widmo o równomiernym rozkładzie energii (szum biały), natomiast wartości bliskie zeru charakteryzują sygnały tonalne z wyraźnymi dominującymi składowymi harmonicznymi. Cecha ta jest

zdefiniowana jako deskryptor niskiego poziomu (LLD) w standardzie MPEG-7 (*AudioSpectrumFlatness*). Średnia geometryczna obliczana jest z użyciem logarytmów w celu uniknięcia niedomiarów numerycznych przy mnożeniu dużej liczby małych wartości.

2.4.7 Współczynnik szczytu widmowego (Spectral Crest Factor)

$$SCF(b,n) = \frac{\max_i(S_n^2(i))}{\frac{1}{ih(b)-il(b)+1}\sum\limits_{i=il(b)}^{ih(b)} S_n^2(i)}$$

Współczynnik szczytu widmowego jest stosunkiem maksymalnej wartości gęstości widmowej mocy do jej średniej arytmetycznej w danym paśmie częstotliwości. Wysoka wartość SCF wskazuje na obecność wyraźnego szczytu dominującego w paśmie (sygnał tonalny), natomiast wartość bliska jedności świadczy o równomiernym rozkładzie energii. SCF jest interpretowany jako kwadrat stosunku amplitudy szczytowej do wartości skutecznej (RMS) w dziedzinie widmowej. Podobnie jak SFM, obliczany jest osobno dla każdego z czterech pasm krytycznych.

2.5 Spektrogram

Spektrogram jest dwuwymiarową reprezentacją sygnału audio, łączącą informacje o czasie, częstotliwości i energii w jednej wizualizacji. Oś pozioma odpowiada czasowi, oś pionowa częstotliwości, natomiast kolor każdego punktu reprezentuje wartość energii widmowej wyrażoną w decybelach:

$$P(n,k) = 20 \cdot \log_{10}(S_n(k))$$

Spektrogram jest graficzną reprezentacją macierzy widm ramkowych $S_n(k)$ – każda pionowa kolumna odpowiada widmu pojedynczej ramki, identycznemu z tym wyświetlanym na wykresie widma ramki. Skala decybelowa jest stosowana zamiast skali liniowej, ponieważ lepiej odpowiada logarytmicznej charakterystyce ludzkiego układu słuchowego i pozwala jednocześnie uwidocznić zarówno silne jak i słabe składowe widmowe.

Jakość spektrogramu zależy bezpośrednio od parametrów analizy ramkowej i wiąże się z fundamentalną zasadą nieoznaczoności czasu i częstotliwości: nie jest możliwe uzyskanie jednocześnie wysokiej rozdzielczości czasowej i częstotliwościowej. Duży rozmiar ramki N zapewnia lepszą rozdzielczość częstotliwościową ($\Delta f = f_s/N$), ale gorszą czasową, natomiast mały rozmiar ramki daje dokładniejszą lokalizację zdarzeń w czasie kosztem rozdzielczości częstotliwościowej. Stopień nakładania ramek (overlap) kontrolowany parametrem Hop Size dodatkowo wpływa na gęstość próbkowania czasowego spektrogramu.

2.6 Cepstrum i częstotliwość tonu podstawowego

2.6.1 Cepstrum

Cepstrum zostało zdefiniowane w 1963 roku przez Bogerta, Healy'ego i Tukey'a. Nazwa jest anagramem słowa *spectrum* i odzwierciedla fakt, że operacja cepstrum bazuje na transformacji Fouriera zastosowanej dwukrotnie. Cepstrum rzeczywiste $C(\tau)$ definiowane jest jako:

$$C(\tau) = \mathcal{F}^{-1}\left(\log|\mathcal{F}(s(t))|\right)$$

gdzie $s(t)$ oznacza sygnał w dziedzinie czasu, $\mathcal{F}$ transformację Fouriera, a $\mathcal{F}^{-1}$ odwrotną transformację Fouriera. Wynikiem jest przebieg pseudoczasowy – oś odciętych nosi nazwę *quefrency* (od ang. *frequency*) i wyrażona jest w sekundach jako $\tau = i/f_s$, gdzie i jest indeksem próbki cepstrum.

Obliczenia wykonywane są w trzech krokach:

1. Obliczenie widma amplitudowego ramki za pomocą FFT: $|S_n(\omega)|$
2. Logarytmowanie widma amplitudowego: $\log |S_n(\omega)|$
3. Zastosowanie odwrotnej FFT do wyznaczenia cepstrum: $C(\tau) = |\mathcal{F}^{-1}(\log |S_n(\omega)|)|$

Pierwsza próbka cepstrum ($\tau = 0$) zawiera całkowitą energię logarytmiczną ramki i dominuje nad pozostałymi wartościami – nie jest użyteczna przy wyznaczaniu tonu podstawowego i jest pomijana w wizualizacji. Pozostałe próbki kodują strukturę harmoniczną sygnału: jeśli sygnał zawiera periodyczną strukturę harmoniczną (jak w przypadku dźwięków mowy lub muzyki), w cepstrum pojawia się wyraźne lokalne maksimum w okolicy quefrency odpowiadającej okresowi podstawowemu.

2.6.2 Częstotliwość tonu podstawowego (F0)

Częstotliwość tonu podstawowego (ang. *Fundamental Frequency*, F0), nazywana również częstotliwością krtaniową, jest najniższą częstotliwością periodyczną sygnału mowy. Dla głosu ludzkiego F0 mieści się typowo w przedziale 50–400 Hz, przy czym dla mężczyzn wynosi zazwyczaj 80–150 Hz, a dla kobiet 150–300 Hz.

Szacowanie F0 na podstawie cepstrum polega na wyznaczeniu położenia lokalnego maksimum rzeczywistego cepstrum w przedziale odpowiadającym poszukiwanemu zakresowi częstotliwości:

$$f_0 = \frac{1}{\tau_{\max}}, \quad \tau_{\max} = \arg \max_{\tau \in [\tau_{\min}, \tau_{\max}]} C(\tau)$$

gdzie granice przedziału poszukiwań wyznaczane są jako:

$$\tau_{\min} = \left\lfloor \frac{f_s}{f_{0,\max}} \right\rfloor, \qquad \tau_{\max} = \left\lfloor \frac{f_s}{f_{0,\min}} \right\rfloor$$

co dla $f_s = 22050$ Hz i przedziału 50–400 Hz daje indeksy od 55 do 441 próbki cepstrum. Wizualizacja cepstrum ograniczona jest właśnie do tego przedziału.

Surowe wartości F0 mogą zawierać błędy w ramkach bezdźwięcznych lub cichych, gdzie cepstrum nie wykazuje wyraźnej struktury harmonicznej. W celu odfiltrowania takich ramek stosowany jest próg energetyczny – ramki o energii poniżej zadanej wartości progowej otrzymują wartość F0 równą zero.

3 Wyniki

3.1 Wpływ funkcji okienkowych na widmo i spektrogram

Funkcja okienkowa jest stosowana do każdej ramki sygnału przed obliczeniem FFT. Jej zadaniem jest wygładzenie nieciągłości na brzegach ramki – bez okienkowania sygnał jest gwałtownie obcinany, co wprowadza do widma sztuczne składowe wysokoczęstotliwościowe. Zjawisko to nosi nazwę *wycieku widmowego* (ang. *spectral leakage*).

3.1.1 Okno prostokątne

Okno prostokątne mnoży każdą próbkę ramki przez 1, czyli w praktyce nie modyfikuje sygnału. Jest to równoważne gwałtownemu obcięciu sygnału na brzegach ramki. W rezultacie energia składowej o danej częstotliwości "wycieka"do sąsiednich binów, co objawia się na spektrogramie jako:

- wyraźne, twarde krawędzie między obszarami o różnej energii
- duże lokalne kontrasty między sąsiadującymi pikselami
- pozorne wzmocnienie szerokopasmowego szumu wokół silnych składowych harmonicznych

Zaletą okna prostokątnego jest zachowanie pełnej amplitudy sygnału — żadna próbka nie jest tłumiona, przez co spektrogram wydaje się jaśniejszy niż przy innych oknach.

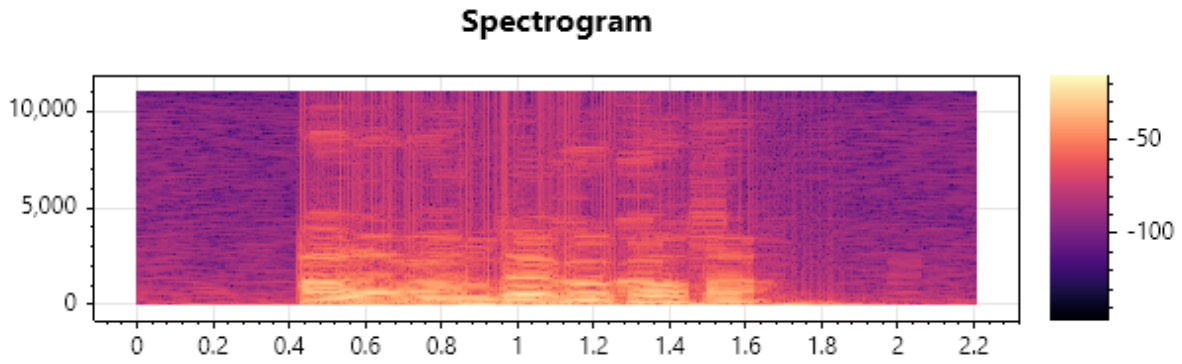

Rysunek 2: Spektrogram z oknem prostokątnym

3.1.2 Okno Hanninga

Okno Hanninga (van Hanna) wygładza próbki na brzegach ramki do zera według funkcji cosinusoidalnej, co znacznie redukuje wyciek widmowy. Na spektrogramie efekt jest wyraźnie widoczny:

- płynne przejścia między obszarami o różnej energii
- gładszy wygląd spektrogramu, lepiej widoczna struktura harmoniczna
- wyraźniejsze rozgraniczenie między obszarami ciszy a obszarami dźwięcznymi

Ceną za redukcję wycieku jest pewne poszerzenie głównego płata widma każdej składowej harmonicznej (ang. *main lobe widening*) — pojedyncza częstotliwość zajmuje nieznacznie więcej binów niż przy oknie prostokątnym. Ponadto, ponieważ współczynniki okna Hanninga uśredniają się do około 0,5, ogólna energia ramki jest o połowę mniejsza niż przy oknie prostokątnym, co przekłada się na ciemniejszy spektrogram.

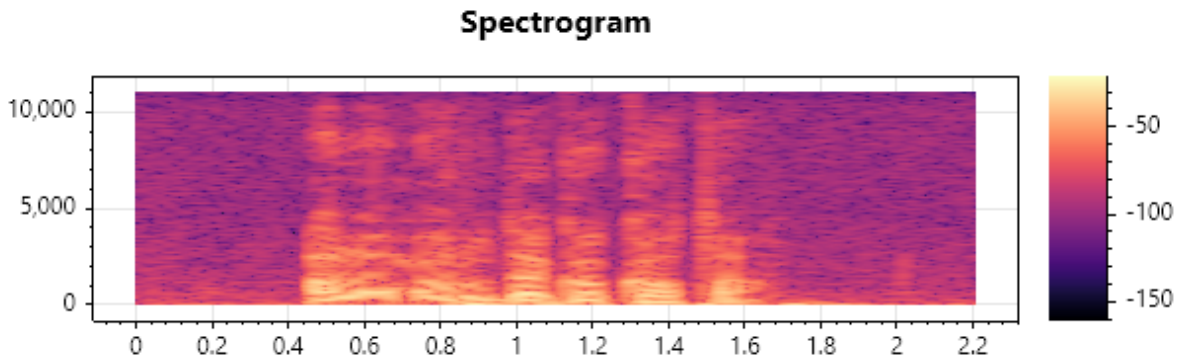

Rysunek 3: Spektrogram z oknem Hanninga

3.1.3 Porównanie

Na rysunku 2 przedstawiono spektrogram powstały w wyniku analizy po użyciu okna prostokątnego, a na rysunku 3 – spektrogram po zastosowaniu okna Hanninga. Oba spektrogramy wykonano dla tego samego sygnału, z takimi samymi ustawieniami rozmiaru ramki i rozmiaru skoku.

W przypadku okna prostokątnego wyraźnie widoczny jest wyciek widmowy – obszary wokół silnych składowych harmonicznych mają nieregularną strukturę z dużymi lokalnymi kontrastami. Okno Hanninga eliminuje ten efekt, ujawniając gładką strukturę harmoniczną sygnału i wyraźne przejścia między fragmentami dźwięcznymi a bezdźwięcznymi.

3.2 Samogłoski vs spółgłoski na spektrogramie

3.2.1 Analiza spektrogramu dla wyrazu *aba*

Wyraz *aba* o strukturze samogłoska–spółgłoska–samogłoska pozwala na bezpośrednie porównanie tych dwóch klas głosek na spektrogramie.

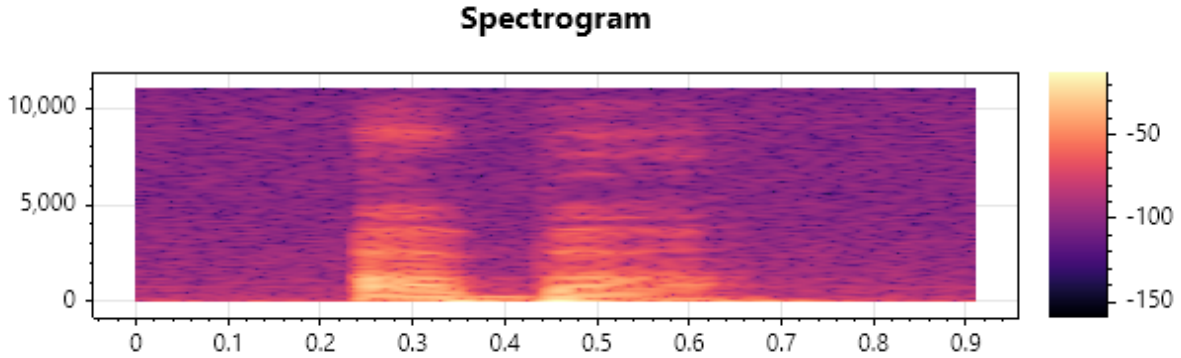

Rysunek 4: Spektrogram wyrazu *aba* – rozmiar ramki 1024, rozmiar skoku 32, okno Hanninga

Samogłoska *a* Obie realizacje samogłoski *a* widoczne są jako obszary gęstych poziomych prążków harmonicznych, zagęszczonych w niskich częstotliwościach i rzedniejących

wraz ze wzrostem częstotliwości. Energia harmonicznych sięga wysokich częstotliwości — widoczny jest wyraźny jasny pasek nawet w okolicy 8,5–9 kHz, odpowiadający wysokiej harmonicznej tonu podstawowego.

Spógłoska zwarta *b* Spółgłoska zwarta *b* objawia się natomiast jako wyraźna przerwa energetyczna — w obszarze powyżej około 400 Hz zanika niemal cała energia, tworząc ciemny obszar dobrze odróżniający się od sąsiednich samogłosek. Kontrast między bogatą strukturą harmoniczną samogłoski *a* a przerwą energetyczną spółgłoski *b* jest na spektrogramie natychmiastowo widoczny.

3.2.2 Analiza spektrogramu dla wyrazu *chrząszcz*

Wyraz *chrząszcz* jest interesującym przykładem do analizy spektrograficznej, ponieważ składa się niemal wyłącznie ze spółgłosek szumiących i zwartoszumiących, z jedną samogłoską nosową pośrodku.

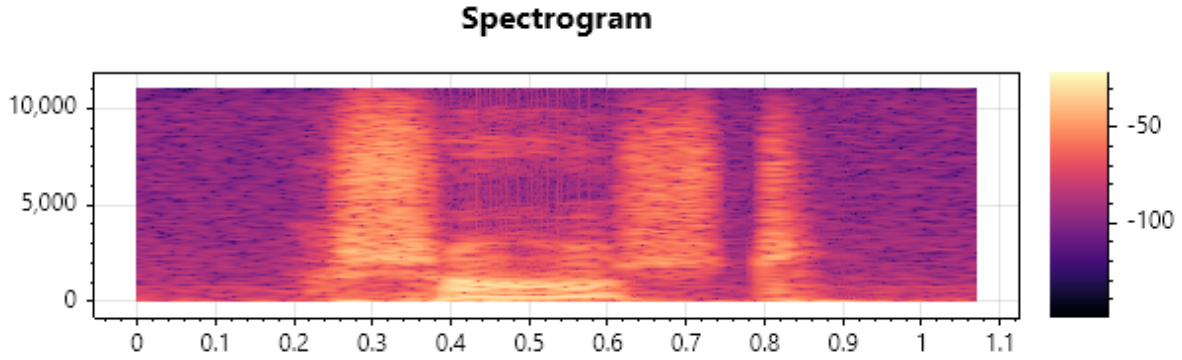

Rysunek 5: Spektrogram wyrazu *chrząszcz* – rozmiar ramki 1024, rozmiar skoku 32, okno Hamminga

Na spektrogramie (rysunek 5) wyraźnie widoczne są charakterystyczne cechy poszczególnych głosek:

Głoski szumiące (ch, rz, sz, cz) Spółgłoski szumiące objawiają się na spektrogramie jako jasne, szerokopasmowe obszary skupione w wysokich częstotliwościach. Energia tych głosek jest równomiernie rozłożona w szerokim paśmie — przykładowo dla *rz* widoczny jest jasny obszar rozciągający się od około 2 kHz do 11 kHz, przypominający kształtem prostokąt. Brak wyraźnej struktury harmonicznej (poziomych prążków) potwierdza bezdźwięczny lub słabo dźwięczny charakter tych głosek — turbulentny przepływ powietrza przez zwężony kanał głosowy generuje szum o szerokim widmie, a nie periodyczny sygnał harmoniczny.

Samogłoska nosowa (ą) Samogłoska *ą* wyraźnie odróżnia się od otaczających ją spółgłosek. Widoczna jest struktura harmoniczna — równomiernie rozmieszczone poziome prążki odpowiadające tonowi podstawowemu i jego harmonicznym — oraz koncentracja energii w niskich częstotliwościach.

3.3 Wyznaczanie częstotliwości tonu podstawowego

Rysunek 6 przedstawia wykres częstotliwości tonu podstawowego wyznaczonej metodą cepstrum dla zdania *Ala ma rudego kota*.

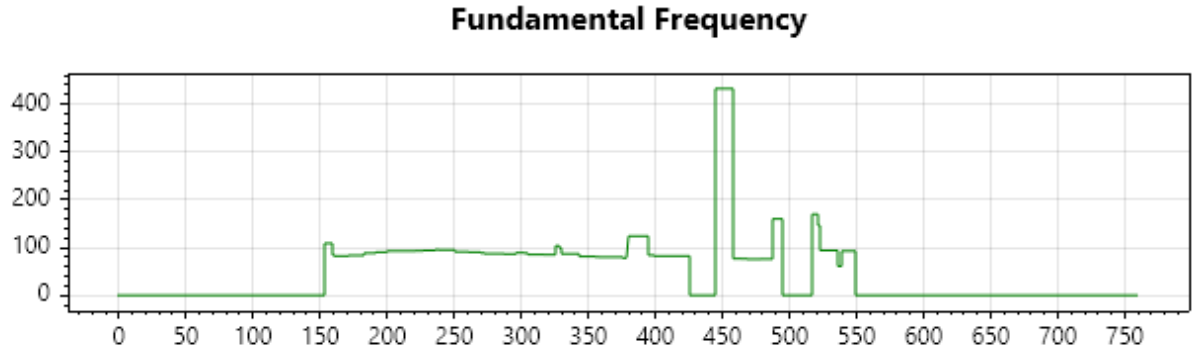

Rysunek 6: Wykres częstotliwości krtaniowej dla zdania *Ala ma rudego kota* – rozmiar ramki 2048, rozmiar skoku 64, okno Hamminga

Wykres składa się z charakterystycznych płaskich odcinków, gdzie wartość F0 pozostaje stała przez kilkanaście kolejnych ramek, po czym skacze do nowej wartości. Jest to spodziewane zachowanie — ton podstawowy zmienia się płynnie podczas mowy, a niska wartość skoku powoduje, że kolejne ramki mocno się nakładają i obejmują podobny fragment sygnału. Wyznaczone wartości F0 mieszczą się w przedziale 80–110 Hz, co jest typowe dla głosu męskiego.

Obok poprawnych wartości widoczne są jednak artefakty — krótkie skoki do wartości znacznie wyższych: około 160 Hz, 170 Hz, a nawet 432 Hz. Tego rodzaju błędy są charakterystyczne dla metody cepstrum i mają dwa główne źródła:

Błędy oktawy Cepstrum wykazuje lokalne maksima nie tylko przy quefrency odpowiadającej F0, ale również przy quefrency odpowiadających harmonicznym (F0/2, F0/3 itd.). Jeśli harmoniczna jest silniejsza niż ton podstawowy — co może się zdarzyć w zależności od fonemu i indywidualnych cech głosu — algorytm błędnie wskazuje ją jako F0, dając wartość będącą wielokrotnością rzeczywistego tonu podstawowego. Skoki do 160 Hz i 170 Hz mogą być właśnie podwojeniem rzeczywistego F0 wynoszącego około 80–85 Hz.

Ramki na granicach głosek Skoki do ekstremalnych wartości, jak $\approx$ 432 Hz, odpowiadają ramkom obejmującym przejście między głoską dźwięczną a bezdźwięczną (np. przy spółgłosce k w słowie „kota"). W takich ramkach sygnał nie ma wyraźnej struktury periodycznej, cepstrum nie wykazuje dominującego maksimum w oczekiwanym przedziale quefrency, a algorytm wskazuje przypadkowy szum jako F0. Tego rodzaju artefakty można częściowo wyeliminować stosując filtr medianowy

3.4 Formanty

Formanty to wzmocnione pasma częstotliwości wynikające z rezonansu traktu głosowego – każda samogłoska ma charakterystyczny układ formantów F1 i F2. Na widmie FFT poje-

dynczej ramki widać je jako lokalne maksima ponad strukturą harmoniczną. Przykładowe wartości dla języka polskiego:

Samogłoska	F1 [Hz]	F2 [Hz]
a	700-800	1100-1300
i	250-350	2200-2800
u	250-350	600-800
e	400-600	1800-2300
o	400-600	700-900

Na rysunku 7 przedstawiono widmo częstotliwościowe pojedynczej ramki z fragmentu, w którym wypowiadana jest samogłoska *u*. Można zaobserwować lokalne maksimum dla częstotliwości ok. 250 Hz, a także mniejsze maksimum lokalne dla około 740 Hz. Wartości te zgadzają się z wartościami teoretycznymi.

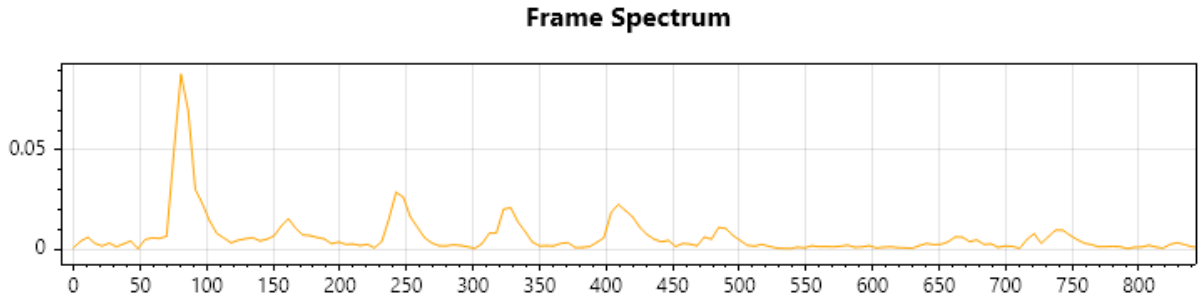

Rysunek 7: Widmo częstotliwościowe ramki z samogłoską *u*

4 Wnioski

W ramach projektu zrealizowano aplikację umożliwiającą analizę częstotliwościową sygnałów mowy. Na podstawie przeprowadzonych eksperymentów sformułowano następujące wnioski:

Parametry analizy ramkowej Rozmiar ramki i rozmiar skoku są kluczowymi parametrami wpływającymi na jakość analizy. Zwiększenie rozmiaru ramki poprawia rozdzielczość częstotliwościową kosztem rozdzielczości czasowej – jest to bezpośrednia konsekwencja zasady nieoznaczoności czasu i częstotliwości.

Funkcje okienkowe Wybór funkcji okienkowej ma istotny wpływ na jakość analizy widmowej. Okno prostokątne, choć zachowuje pełną amplitudę sygnału, wprowadza wyciek widmowy objawiający się nieregularną strukturą spektrogramu i fałszywymi składowymi widmowymi. Okno Hamminga, okno Hanninga, itp. skutecznie eliminują ten efekt, ujawniając gładką strukturę harmoniczną sygnału.

Rozróżnienie klas głosek Analiza spektrogramów potwierdziła fundamentalne różnice między klasami głosek. Różnice te są natychmiastowo widoczne na spektrogramie i dobrze korelują z fizycznym mechanizmem powstawania dźwięków mowy.

Formanty W widmie FFT pojedynczych ramek samogłoskowych zaobserwowano formanty – lokalne maksima odpowiadające rezonansom traktu głosowego. Wyznaczone wartości formantów dla samogłoski *u* są zgodne z wartościami teoretycznymi dla języka polskiego, co potwierdza poprawność zaimplementowanej analizy widmowej.

Częstotliwość tonu podstawowego Metoda cepstrum pozwala na skuteczne wyznaczenie F0 dla dźwięcznych fragmentów sygnału mowy. Wyznaczone wartości F0 w przedziale 80–110 Hz są zgodne z typowymi wartościami dla głosu męskiego.